RADAR

推理能力与难度感知的推理大语言模型路由

RADAR: Reasoning-Ability and Difficulty-Aware Routing for Reasoning LLMs

Nigel Fernandez[1*] ·Branislav Kveton[2] ·Ryan A. Rossi[2] ·Andrew S. Lan[1] ·Zichao Wang[2]

[1] University of Massachusetts Amherst [2] Adobe Research

发表于 ICLR 2026 ·arXiv:2509.25426

中文译本说明：根据此前逐节译文整理，针对原论文正文第 1—5 章排版；图 1—3 使用原论文矢量图，表 1—3 保留原数值，参考文献保留英文。附录 A—E 未收录。本译本并非作者官方译稿。原论文公式（1）—（9）已逐式对照。

摘要（Abstract）

推理语言模型（Reasoning Language Models，RLMs）在数学、科学和编程等具有挑战性的任务上表现出卓越的性能。在实际部署中，选择合适的推理模型需要在两个关键层面权衡性能与成本：模型规模和推理预算（reasoning budget）。较大的模型和较高的推理预算通常带来更好的性能，却也产生更高的成本与延迟。本文从针对不同问题进行模型配置路由的角度研究这一权衡，并提出 RADAR（Reasoning–Ability and Difficulty-Aware Routing），一种轻量级、可解释且可扩展的路由框架。受心理测量学启发，RADAR 根据不同模型在不同推理预算下对不同问题的回答结果，学习一个项目反应模型（item response model），其中包括问题难度和模型—预算配置能力等具有可解释性的参数。RADAR 随后将较难的问题路由到能力较强的模型—预算组合，将较易的问题路由到能力较弱的组合。我们在八个广泛使用的高难度推理基准上进行了大量实验，表明 RADAR 相比先进模型路由方法具有更优的表现。RADAR 还展示了问题泛化能力，在所有基准的分布外问题上取得良好性能。此外，RADAR 可以动态选择少量评估问题来估计新增模型的能力，从而高效地将更多模型集成到配置池中。

* 第一作者的工作完成于 Adobe Research 实习期间（原文脚注）。

1 引言（Introduction）

近年来，大语言模型（Large Language Models，LLMs）的发展利用强化学习（Reinforcement Learning，RL）（Shao et al., 2024），训练模型在生成最终输出之前先通过思维链（chain-of-thought）进行推理。这些推理语言模型（RLMs）（Yang et al., 2025; Guo et al., 2025; OpenAI & et al., 2024）已经在数学（MAA, 2024）、科学（Rein et al., 2024）、编程（Jimenez et al., 2024）、视觉感知（Lu et al., 2024）和工具使用（Yao et al., 2025）等多种高难度任务上表现出令人印象深刻的性能。这一发展催生了大量新的开源和专有 RLM。例如，截至 2026 年 3 月 8 日，Hugging Face 已列出 4,492 个 RLM。这些模型规模不同，专长领域各异，并提供多种配置（包括推理预算），以在性能与成本之间取得平衡。例如，OpenAI 推理模型（OpenAI & et al., 2024）提供了 low、medium 和 high 三档推理预算，以便开发者根据实际应用选择。

然而，对于每个问题，始终选择具有最高推理预算、最强且最昂贵的 RLM 配置，并不一定是最合适的决策。对于较简单的问题，可能存在性能较弱、成本更低且推理预算较低甚至为零的配置，同样能够正确回答问题，从而在不牺牲性能的情况下显著节省成本。我们在图 1 中的实验也观察到了同样的现象：MATH-500（Hendrycks et al., 2021c）中超过 50% 的问题，仅使用 Qwen3-0.6B 这样的小模型和极少的推理预算（以推理 token 数衡量）就能解决。相反，某些高难度问题需要能力更强且推理预算更高的 RLM。较强的 RLM 还可能出现“过度思考”（over-thinking），即使面对简单问题也可能因此损害性能（Su et al., 2025; Hassid et al., 2025; Hong et al., 2025; Shojaee et al., 2025; Ghosal et al., 2025）。

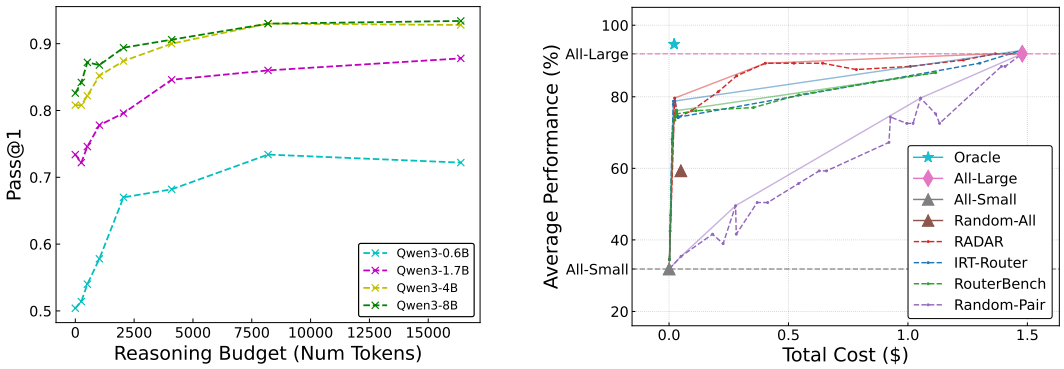


图 1: 左：在 MATH-500 上，不同（RLM，推理预算）配置的性能差异；最小模型仅用极少推理量即可解决超过 50% 的问题。右：RADAR 联合估计问题难度与配置能力，将问题路由到能力足够的配置，使性能—成本权衡结果接近帕累托前沿。对于 FRAMES 的分布外问题，RADAR 仅以 o4-mini 高预算成本的 10% 达到其 90% 的性能；次佳方法需要 30% 成本。实线表示各曲线的凸包。

图内英文坐标轴及图例保留原始论文内容。

这种性能—成本权衡为实际应用提出了一个挑战：**如何选择能够正确回答给定问题、具有足够能力的 RLM 及其配置（如推理预算），同时最大化性能并最小化成本?**

本文提出 RADAR（Reasoning-Ability and Difficulty-Aware Routing）框架，以解决上述挑战。给定一个由 {RLM, 推理预算} 构成的配置池、用户偏好的性能—成本权衡设定及一个新问题，RADAR 会据此选出该问题的最优配置。RADAR 轻量且高效：它在问题级别实时完成决策，额外延迟约为 7 毫秒；配置分配发生在 RLM 接收问题之前，因而在生成过程中不需要切换模型，可避免级联路由器（Chen et al., 2023; Zhang et al., 2024）可能产生的重复调用以及 KV-cache 重算。RADAR 也具有即插即用（plug-and-play）的特点：它将 RLM 当作黑盒，无须微调，可直接通过标准 API 使用。当新的 RLM 可用时，RADAR 能够快速将其加入未来路由的候选配置池。

RADAR 的关键机制是定制的项目反应理论（Item Response Theory，IRT）模型。这一经典方法起源于心理测量学和教育评价（Rasch, 1960; Lord, 2012; van der Linden & Hambleton, 1997; DeMars, 2010）。我们使用 IRT 联合估计可解释的问题难度，以及模型在不同推理预算下的能力。首先执行校准（calibration）：收集各个 {RLM，推理预算} 配置对一组问题的评估结果；然后使用 IRT 对响应矩阵建模，学习潜在的能力和难度参数。为了泛化到分布外（OOD）问题，我们通过一个可学习向量参数化问题难度，将其与预训练嵌入模型产生的问题向量相乘，得到难度值；每个模型配置则用一个可学习的标量能力值表示。加入新配置时，使用受教育评价中自适应测验（adaptive testing）启发的方法，动态选择少量问题估计其能力（Wainer et al., 2000; Hofmann et al., 2025）。这些设计使 RADAR 能够实时处理新问题，并泛化到新模型配置。

我们还将模型配置选择表述为多目标优化（Multi-Objective Optimization, MOO），采用标量化方法在性能—成本帕累托前沿上搜索配置（Miettinen, 1999）。MOO 是成熟的多目标优化框架（Keeney & Raiffa, 1993; Emmerich & Deutz, 2018），已广泛应用于工程（Marler & Arora, 2004）、产品设计与制造（Wang et al., 2011）以及经济学（Ponsich et al., 2013）。本文首次在 LLM 路由中使用超越线性标量化的 MOO 技术。我们在八个公认的高难度推理基准上进行了大量实验，RADAR 显示出优于现有路由方法的性能。例如，在 MATH-500 上，仅使用 OpenAI o4-mini 高预算成本的 1.31%，RADAR 就能达到其 90% 的性能。尽管主要在短问题上训练，RADAR 仍对长上下文多文档问答（Krishna et al., 2024）等 OOD 问题表现出较强泛化能力，并能良好地扩展到新模型配置，进一步改善路由性能。

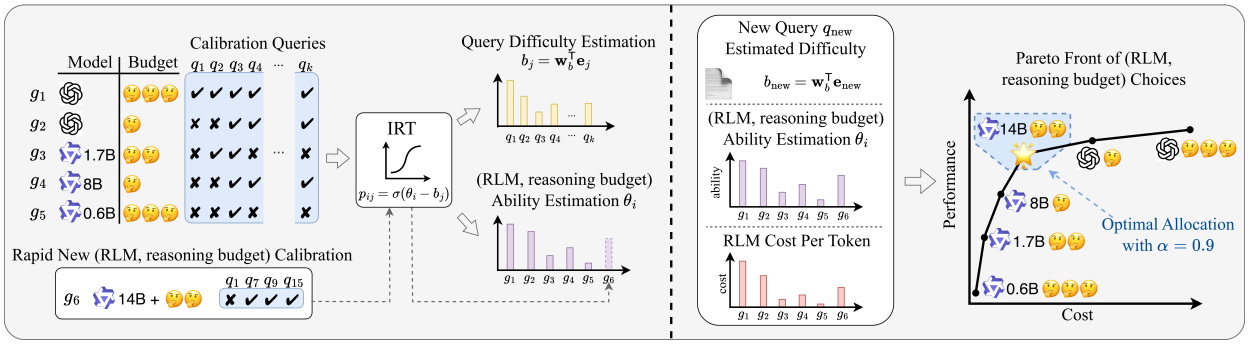


图 2: RADAR 框架示意图。左：通过 IRT 联合估计可解释的问题难度与模型配置能力（图示经过简化，完整细节见第 3.3 节）；对于新增模型配置，借助自适应测验从少量动态选择的问题中估计其能力（第 3.5 节）。右：将路由表述为 MOO，将问题分配给能力足够的配置，使性能—成本权衡向帕累托前沿靠近（第 3.2 节）。示意图使用原论文矢量内容，图内英文标签未改动。

本文的主要贡献总结如下：

[C1] 将自适应推理表述为对离散化模型—预算配置的路由，并在黑盒环境下基于帕累托最优性能—成本目标选取配置。

[C2] 将 IRT 用于从数据中学习可解释的问题难度和配置能力，实现低延迟路由以及对未见问题的泛化。

[C3] 通过自适应校准，从少量具有信息量的问题子集中估计能力，支持新推理模型的即插即用式集成。

[C4] 在八个高难度推理基准中取得更优的性能—成本权衡及较强的 OOD 泛化，包括长上下文文档问答。

2 相关工作（Related Work）

高效推理（Efficient Reasoning） 日益增多的工作致力于提高推理模型本身的效率，参见 Yue et al.（2025）的综述。L1（Aggarwal & Welleck, 2025）和 S1（Muennighoff et al., 2025）等方法通过控制长度，鼓励产生能够给出正确答案的更短思维链。其他方法通过动态缩短或延长推理过程（Hou et al., 2025; Xu et al., 2025; Wang et al., 2025），或者自适应控制推理步骤（Huang et al., 2025）来修剪或调整推理，并分析何时额外推理有益、何时属于浪费（Su & Cardie, 2025; Su et al., 2025; Yu et al., 2025; Ghosal et al., 2025）。我们的方法与单模型效率优化互补：这些高效 RLM 均可成为 RADAR

额外的路由候选配置。与需要访问模型权重的静态单模型调节不同，RADAR 在黑盒环境下利用异构模型间的互补优势，并根据用户应用动态调整性能—成本权衡。

基础模型路由（Routing for Foundation Models） 近期模型路由研究（Ding et al., 2024; Ong et al., 2024; Chen et al., 2025; Hu et al., 2024; Zhang et al., 2025）主要关注使用黑盒预测器进行模型选择或采用模型级联（Chen et al., 2023）。与之不同，我们从模型—预算联合配置的角度研究 RLM 自适应推理，将路由表述为 MOO。与不透明的路由回归器（Chen et al., 2023; Ding et al., 2024; Ong et al., 2024）不同，RADAR 采用 IRT 参数化，使潜在的问题难度和配置能力具有可解释性。相比同期基于 IRT 的路由方法（Song et al., 2025），本研究：（1）将此前尚未探索的 RLM 路由表述为 MOO，从而采用切比雪夫标量化等更丰富的求解技术；（2）使用参数更少的 IRT 表述，实现可解释的标量能力排序，可能降低训练数据需求；（3）提供评估帕累托前沿覆盖程度的新 MOO 路由指标；（4）使用自适应测验快速泛化到新 RLM。扩展讨论和详细比较见原论文附录 A。

3 方法论（Methodology）

本节介绍通过路由 RLM 配置实现自适应推理的 RADAR 框架。我们首先将自适应推理形式化为 MOO：对于指定的性能—成本权衡，路由器选取最优的 {RLM，推理预算} 配置。在这一问题表述下，我们进一步介绍如何通过 IRT 预测某个模型配置在给定问题上的性能，以及如何求解优化问题。

3.1 通过离散化实现基于路由的自适应推理

与传统模型路由（Ong et al., 2024; Ding et al., 2024）从不同基础模型中选择不同，实际部署 RLM 时必须同时考虑基础模型和推理预算两个层面的性能—成本权衡。我们将每个 RLM $m \in \mathcal{M}$ 按其可用预算 $u \in \mathcal{U}_m$ 离散化，以统一这两个决策。例如，专有模型（如 o4-mini）的预算可以为 $\{\text{low}, \text{medium}, \text{high}\}$，开源模型的用户自定义预算集合可以为 $\{0, 1k, 2k, 4k, 8k, 16k\}$。

对于开源 RLM（如 Qwen3），我们在生成期间统计思考 token 数。一旦超过设定预算，就附加中断消息（如“output answer based on current thinking”）及模型的思考结束 token（例如 `</think>`），结束思维链并提前进入最终答案生成。每个离散化组合称为一个模型配置 $g = (m, u) \in \mathcal{G}$，其中候选配置集合满足：

$$\mathcal{G} \subseteq \bigcup_{m \in \mathcal{M}} \bigcup_{u \in \mathcal{U}_m} \{(m, u)\}.$$

离散化使模型路由能够在配置层面运行。本文使用更通用的“配置”一词，因为 RADAR 除推理预算外，还可以选择附加 RAG 流水线的参数设置或解码方式。

3.2 将 RLM 路由表述为多目标优化问题

我们从 MOO 的视角重新审视模型路由，从而使用相关文献中的成熟求解技术（Miettinen, 1999; Branke et al., 2008; Murata & Ishibuchi, 1995; Zhang & Golovin, 2020）。给定问题集合 $\mathcal{Q} = \{q_1, \ldots, q_k\}$ 和候选配置集合 $\mathcal{G} = \{g_1, \ldots, g_n\}$，目标是为每个 $q_j \in \mathcal{Q}$ 选择最优配置 $g_i \in \mathcal{G}$，使性能最大且成本最小。

对于单个问题 q（为简洁起见略去索引），定义两个目标：性能预测函数 $p_q : \mathcal{G} \to [0, 1]$，表示配置 g 回答 q 的正确概率；成本预测函数 $c_q : \mathcal{G} \to [0, 1]$，表示归一化后的回答成本。我们将其表

述为二维的先验多目标优化问题（a-priori MOO），使用标量化技术求解：

$$g^* = \arg\max_{g\in\mathcal{G}} f(p_q(g), c_q(g)). \tag{1}$$

其中 f 是标量化函数。标量化将 MOO 的多个目标聚合为单目标优化问题（SOP），使 SOP 的最优解成为 MOO 的帕累托最优解。本文研究线性标量化与切比雪夫标量化两种技术。

3.2.1 线性标量化（Linear Scalarization）

线性标量化（Murata & Ishibuchi, 1995）给每个目标赋予非负权重，并最大化奖励的加权和（等价地最小化成本加权和）。调整权重可以得到性能—成本帕累托前沿上的不同点。对于 $\mathbf{w} \in \mathbb{R}^2_{\geq 0}$，相应的线性标量化问题为：

$$\arg\max_{g\in\mathcal{G}} \Big[w_1 p_q(g) + w_2(-c_q(g)) \Big]. \tag{2}$$

由于权重可以提取乘法常数，我们约束其和为 1。对于二维 MOO，可设 $w_2 = 1 - w_1$，于是：

$$\mathrm{LSP}_q^{w_1} = \arg\max_{g\in\mathcal{G}} \left[w_1 p_q(g) - (1-w_1) c_q(g) \right]. \tag{3}$$

需要指出，式（3）恢复了已有路由方法（Hu et al., 2024; Song et al., 2025; Zhang et al., 2025）使用的路由形式，但这是从 MOO 视角得到的。

3.2.2 切比雪夫标量化（Chebyshev Scalarization）

通常，当帕累托前沿非凸时，前沿上的某些点不可能作为任何权重参数化 LSP 的最优解。因此，我们也研究切比雪夫标量化（Zhang & Golovin, 2020），通过到理想参考点的加权切比雪夫距离，找到前沿凹陷部分的点。本文理想参考点对应性能为 1、成本为 0。该方法旨在最小化所有维度上、相对于理想参考点的权重缩放后的最大惩罚。对于 $\mathbf{w} \in \mathbb{R}^2_{\geq 0}$，相应问题为：

$$\mathrm{CSP}_q^{w_1} = \arg\min_{g\in\mathcal{G}} \max \left\{ w_1 |1 - p_q(g)|, (1-w_1) c_q(g) \right\}. \tag{4}$$

权重 w_1 控制性能与成本的权衡：较大值更重视性能，从而更频繁地选用能力较强的配置；较小值更重视成本效益，从而更倾向于较弱但更经济的配置。给定权重 w_1 和问题 q，RADAR 选择 $g = \mathrm{LSP}_q^{w_1}$ 或 $g = \mathrm{CSP}_q^{w_1}$，以最大化性能并最小化成本。

3.3 基于 IRT 的推理能力与问题难度校准

准确参数化性能预测函数 $p_q(g)$ 是求解式（1）的关键。我们使用常用于学生作答建模的项目反应理论（IRT）（Rasch, 1960; Lord, 2012; van der Linden & Hambleton, 1997; DeMars, 2010），具体采用双参数逻辑模型（two-parameter logistic，2PL）（Lord, 1951; Birnbaum, 1968）。IRT 假设单调性，即随着配置能力增加，其正确回答某个问题的概率也随之增大。2PL 考虑问题的两个属性：难度和区分度。直观地说，回答某个问题正确后，配置能力估计受到的影响取决于问题难度；区分度则描述正确概率随着配置能力增加而上升的速率差异。

在 RADAR 中，我们通过冻结参数的嵌入模型，将问题 q_j 映射为 d_q 维向量 $\mathbf{e}_j$。借助嵌入表示的问题内容，RADAR 可泛化到 OOD 问题，包括长上下文多文档问答，即使训练数据主要是短问

题。我们通过线性变换获得标量难度 $b_j \in \mathbb{R}$ 与区分度 $a_j \in \mathbb{R}$：

$$a_j = \mathbf{w}_a^\top \mathbf{e}_j, \qquad b_j = \mathbf{w}_b^\top \mathbf{e}_j,$$

其中 $\mathbf{w}_a, \mathbf{w}_b \in \mathbb{R}^{d_q}$ 为可学习的向量。采用简单线性变换和冻结嵌入模型有助于降低路由延迟，详见第 4.3 节与原文附录 B.1。对于模型配置 g_i，使用标量能力参数 $\theta_i \in \mathbb{R}$。在 2PL 模型下，配置 g_i 正确回答问题 q_j 的概率为：

$$p_{ij} = \sigma(a_j(\theta_i - b_j)),$$

其中 $\sigma(\cdot)$ 为 sigmoid 函数。

同期基于 IRT 的模型路由方法（Song et al., 2025）使用多维 IRT 模型（MIRT）（Reckase, 2009）参数化性能函数。不同的是，我们使用标量配置能力，使能力数值能够提供可解释的模型排序。2PL 的参数数量较少，因而所需训练数据更少。此外，Song et al.（2025）采用定性模型画像嵌入进行新模型泛化；我们采用自适应测验快速估计新增配置的标量能力，从而将其快速加入后续路由池（见第 3.5 节）。

为了训练 IRT，构建二值评估矩阵 $Y \in \{0,1\}^{n \times k}$，记录 n 种 RLM 配置在 k 个训练问题上的回答结果。最小化全部 nk 个观测结果的平均负对数似然（即二元交叉熵）：

$$\mathcal{L}_{\text{2PL}} = -\frac{1}{nk} \sum_{i=1}^{n} \sum_{j=1}^{k} \left[y_{ij} \log p_{ij} + (1 - y_{ij}) \log(1 - p_{ij}) \right]. \tag{5}$$

其中 $p_{ij} = \sigma(a_j(\theta_i - b_j))$ 表示 2PL IRT 估计的正确回答概率。

3.4 成本预测（Cost Prediction）

除性能预测函数外，求解路由 MOO（式（1））还需要成本预测函数 $c_q(g)$。遵循 Hu et al.（2024）及 Song et al.（2025），我们采用启发式方法：计算配置 g 在问题 q 上产生的推理 token 数 $n_g^{\text{rsn}}(q)$ 与答案 token 数 $n_g^{\text{cmp}}(q)$ 之和，乘以该基础 RLM 的每 token 成本 t_g，然后对全部训练问题求平均：

$$c_q(g) = \frac{1}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} \Big(n_g^{\text{rsn}}(q) + n_g^{\text{cmp}}(q) \Big) t_g. \tag{6}$$

专有模型（如 o4-mini）的每 token 美元成本从官方网站获取；开源模型（如 Qwen3）的价格来自云服务提供商[1]。使用最小—最大归一化将配置成本 $c_q(g)$ 缩放到 $[0,1]$，保证预测成本与预测性能处于相同尺度。更复杂的成本预测方法留待未来研究。

3.5 通过自适应测验扩展 RLM 配置池

为 RADAR 加入新的模型配置 g_i，需要准确估计其标量能力 $\hat{\theta}_i \in \mathbb{R}$。给定拟合后的 2PL 模型以及学得的问题参数 $\{a_j, b_j\}_{j=1}^{|\mathcal{Q}|}$，可以通过观察该配置对问题子集 $S \subseteq \mathcal{Q}$ 的回答，估计 $\hat{\theta}_i$。相应的负对数似然定义为：

$$\begin{aligned} \mathcal{L}_{\text{2PL}}(\theta; S, g_i) = -\sum_{j \in S} \big[& y_{ij} \log \sigma(a_j(\theta - b_j)) \\ & + (1 - y_{ij}) \log(1 - \sigma(a_j(\theta - b_j))) \big]. \end{aligned} \tag{7}$$

[1]原文价格来源：https://www.together.ai/pricing。

其中 $y_{ij} \in \{0,1\}$ 表示新配置 g_i 对 q_j 的回答结果。能力估计为 $\hat{\theta}_i = \arg\min_\theta \mathcal{L}_{\text{2PL}}(\theta; S, g_i)$。完整评估对应 $S = \mathcal{Q}$，即 $\hat{\theta}_i = \arg\min_\theta \mathcal{L}_{\text{2PL}}(\theta; \mathcal{Q}, g_i)$；但评估所有问题的计算成本较高。

为降低成本，我们采用受到计算机化自适应测验（computerized adaptive testing）（Wainer et al., 2000）启发的自适应问题选择策略。对于新配置 g_i，逐步构造评估子集 S_t，下文省略配置索引 i。初始化 $S_0 = \emptyset$、$\hat{\theta}_0 = 0$。对于 $t \geq 1$，受到 Hofmann et al.（2025）启发，选择在当前能力估计附近具有最大费舍尔信息量（Fisher information）的未评估问题：

$$j_t = \arg\max_{j \in \mathcal{Q} \setminus S_{t-1}} I(\hat{\theta}_{t-1}, a_j, b_j). \tag{8}$$

2PL IRT 的费舍尔信息量为：

$$I(\theta, a_j, b_j) = a_j^2 \sigma(a_j(\theta - b_j)) \left[1 - \sigma(a_j(\theta - b_j))\right]. \tag{9}$$

随后将选中问题加入评估子集：$S_t = S_{t-1} \cup \{q_{j_t}\}$。观察新配置对该题的回答之后，更新能力估计 $\hat{\theta}_t = \arg\min_\theta \mathcal{L}_{\text{2PL}}(\theta; S_t, g_i)$。重复这一过程，直至 $|S_t|$ 达到预算 T，返回 $\hat{\theta}_T$ 作为新增配置的能力估计值。

4 实验评估（Experimental Evaluation）

本节详细介绍用于全面评估 RADAR 的实验设置，包括基准、评估指标和基线方法。

基准测试（Benchmarks） 我们在八个推理基准上进行评估：AIME（MAA, 2024）、MATH（Hendrycks et al., 2021c）、GPQA（Rein et al., 2024）、LSAT（Wang et al., 2022; Zhong et al., 2021）、MMLU（Hendrycks et al., 2021b;a）、MMLU Redux（Gema et al., 2024）、MMLU Pro（Wang et al., 2024）以及 FRAMES（Krishna et al., 2024）。这些基准涵盖竞赛数学、博士级科学问题、法律和通识知识，既有选择题也有开放式回答。特别地，FRAMES 检验 RADAR 在多文档问答场景下对长上下文问题的泛化能力。以往路由研究很少包含长上下文评估；RouterBench（Hu et al., 2024）是一个例外，但它所用的是私有的分布内 RAG 数据集。详细信息见原文附录 C。

评估指标（Metrics） 我们报告超体积（hypervolume）（Emmerich & Deutz, 2018），在本文设置下，它对应于不同 w_1 权重下性能—成本权衡曲线下的面积，数值越高越好。我们还采用成本—性能阈值（Cost–Performance Threshold，CPT），与 Ong et al.（2024）的调用—性能阈值类似：相对于性能最强的配置 o4-mini–high，CPT$(x\%)$ 表示达到其 $x\%$ 性能所需的最小成本，以 o4-mini–high 的成本归一化。例如 CPT$(90\%) = 0.1$ 表示以 10% 的成本达到其 90% 的性能。

基线方法（Baselines） 与近期先进路由方法 RouterBench（Hu et al., 2024; Chen et al., 2025）及 IRT-Router（Song et al., 2025）进行比较。这些方法原生并不支持自适应推理或 RLM 配置级路由，因此我们将其适配到当前实验场景；细节见原文附录 D.3。还包括几种启发式基线：All-Large（o4-mini，高预算）；All-Small（Qwen3-0.6B，0 推理 token）；Oracle（已知测试集性能，选取能够达到最佳表现的配置中最便宜的一项）；Random-All（在所有配置间均匀采样）；Random-Pair（以用户指定的性能—成本权重 w_1 的概率选取最大的配置）。

评估设置与实现细节（Evaluation Setup and Implementation Details） RADAR 使用切比雪夫标量化，同时进行分布内（ID）和分布外（OOD）评估。对于 ID，将全部八个基准的训练划分合并，用来训练 2PL IRT（见第 3.3 节），再分别报告各基准测试划分上的性能；没有预定义测试集的基准按 80%—20% 划分训练集与测试集。对于 OOD，针对一个目标基准，将其他不重叠基准的训练划

分合并成训练集，再于该目标基准的测试集上评估。例如对 AIME 做 OOD 评估时，会从训练集中排除 AIME 以及与其重叠的 MATH（因为 MATH 含有 AIME 的问题）。

表 1: 八个基准的分布内（ID）Hypervolume 路由性能（越高越好）。RADAR 在多数基准上优于对照方法，使性能—成本权衡更接近帕累托前沿。OOD 结果见原文表 13。原文最佳值加粗、次佳值下划线。

基准	Random-Pair	RouterBench	IRT-Router	RADAR（本文）
GPQA-Diamond	0.5545	0.6866	0.6942	**0.7513**
MMLU	0.6905	0.8592	0.8604	**0.8720**
MMLU-Redux	0.7281	0.9053	0.9117	**0.9230**
MMLU-Pro	0.5589	0.7819	0.7812	**0.7995**
LSAT	0.6913	0.9125	0.9163	**0.9188**
AIME	0.5159	0.7680	**0.7766**	0.7760
MATH-500	0.7433	**0.9528**	0.9420	0.9449
FRAMES	0.6589	0.8325	0.8501	**0.8762**

表 2: 八个基准的分布内（ID）CPT(90%) 路由性能（越低越好）。CPT(90%) 是达到 o4-mini 高预算配置 90% 性能所需成本占该配置成本的比例。OOD 结果见原文表 14。原文最佳值加粗、次佳值下划线。

基准	Random-Pair	RouterBench	IRT-Router	RADAR（本文）
GPQA-Diamond	80.36%	57.13%	53.99%	**13.21%**
MMLU	76.30%	2.71%	**2.66%**	2.69%
MMLU-Redux	75.06%	2.59%	2.80%	**2.42%**
MMLU-Pro	83.57%	5.19%	**3.83%**	3.89%
LSAT	80.14%	2.02%	1.93%	**1.82%**
AIME	87.22%	65.65%	61.23%	**60.69%**
MATH-500	76.15%	1.34%	1.44%	**1.31%**
FRAMES	77.90%	43.50%	31.53%	**13.11%**

表 3: 加入 Qwen3-14B 的八种新配置之前（RADAR）与之后（RADAR++）的 Hypervolume，对比 ID 与 OOD 场景（越高越好）。RADAR++ 通过自适应测验估计新配置能力以改善路由性能。每对结果中最佳值加粗，次佳值下划线。

	分布内（ID）		分布外（OOD）	
基准	RADAR	RADAR++	RADAR	RADAR++
GPQA-Diamond	0.7513	**0.7535**	**0.7466**	0.7463
MMLU	0.8720	**0.8731**	0.8609	**0.8698**
MMLU-Redux	0.9230	**0.9238**	0.9072	**0.9091**
MMLU-Pro	0.7995	**0.8021**	0.7858	**0.7951**
LSAT	0.9188	**0.9233**	0.9146	**0.9255**
AIME	0.7760	**0.7828**	**0.7566**	**0.7566**
MATH-500	0.9449	**0.9461**	**0.9368**	**0.9368**
FRAMES	0.8762	**0.8830**	0.8865	**0.8931**

我们共路由 35 种配置：OpenAI o4-mini（low、medium、high 三档推理预算）与 Qwen3 的 0.6B、1.7B、4B、8B 四个模型（各有 0、256、512、1k、2k、4k、8k、16k 八种预算）（Yang et al., 2025; OpenAI, 2025）。使用标准提示词（见原文附录 D.4），每种配置在每个训练问题上评估一次；AIME 的测试集较小，采用八次运行的平均值。结果与文献报告的 RLM 性能相近（Yang et al., 2025; OpenAI, 2025）。在八个基准的训练和测试划分中，总计收集了 50,139 个不重复问题、约 175 万条二值回答结果。其他细节见原文附录 D。

4.1 主要定量结果（Main Quantitative Results）

RADAR 优于先进路由方法 表 1 和表 2 分别报告全部方法在八个基准 ID 设定下的 Hypervolume 和 CPT(90%)。额外阈值的 CPT 结果见原文附录 B.2。RADAR 在多数基准上优于全部基线方法，在其余基准上与最佳已有方法相当。RADAR 优于同期基于 IRT 的 IRT-Router（Song et al., 2025），这表明将 RLM 路由表述为 MOO、并使用切比雪夫标量化等技术，能够更好地恢复性能—成本帕累托前沿。例如，GPQA-Diamond 中 RADAR 的 Hypervolume 比次佳基线高约 8%；对于 MATH-500，其 CPT(90%) 仅为 1.31%，即用 o4-mini 高预算成本的 1.31% 达到其 90% 的性能。其他基准也有类似提升。

问题泛化能力 完整的 OOD Hypervolume 与 CPT(90%) 结果见原文附录 B.3。图 1 给出了 FRAMES（Krishna et al., 2024）的 OOD 帕累托权衡曲线。RADAR 在多数 OOD 基准上优于先进方法。特别地，尽管训练问题主要较短，RADAR 仍在 FRAMES 的高难度长上下文多文档推理问答上表现突出。当 OOD 问题的难度显著高于训练期间所见（如 AIME）时，RADAR 往往分配能力略低于最优水平的配置，导致性能小幅下降；如原文附录 B.4 所示，训练时加入少量代表性问题可缓解这一弱点。

消融实验（Ablation Study） 原文附录 B.5 表明，在 OOD 场景下，切比雪夫标量化优于既有路由工作（Song et al., 2025; Hu et al., 2024）采用的线性标量化，因为它能够探索帕累托前沿的凸区域与凹区域。在 ID 场景下两者表现相近，线性标量化略优。将路由问题表述为 MOO，为未来采用其他 MOO 技术提供了可能。此外，针对训练矩阵规模的消融（原文附录 B.6）发现，即使仅使用随机抽取的 20% 训练问题，RADAR 仍能取得与全量训练集相近的性能。

4.2 模型可扩展性与泛化评估（Model Scalability and Generalization Evaluation）

为评估 RADAR 对新 RLM 的扩展能力，我们加入 Qwen3-14B 提供的八种新配置。表 3 显示，RADAR 通过自适应测验动态选取仅 5,000 个训练问题（约为训练集的 12%），即可准确估计新增配置的能力，从而改善路由性能。与均匀随机采样的比较见原文附录 B.7；加入新配置后路由分配的变化见附录 B.8。相比同期 IRT 路由方法（Song et al., 2025），后者通过询问 ChatGPT 获取新模型的定性画像并将其嵌入；以及已有模型对路由方法（Ding et al., 2024），后者假设新模型对具有相似的能力差异，RADAR 可以准确估计任意新增配置的能力。

4.3 可解释性与延迟分析（Interpretability and Latency Analysis）

可解释的问题难度与配置能力 我们使用 MATH-500（Hendrycks et al., 2021c）中的 ID 问题进行案例研究，该数据集对每道题标注了五个递增难度等级。在图 3 左侧，RADAR 估计的问题难度与五个真实等级之间的皮尔逊相关系数为 0.509，呈中等相关。随着问题难度增加，模型预测能力较强的配置具有更高正确率；在所有配置和问题上的平均答案正确性预测准确率为 84.42%。图 3 右侧展示不同性能—成本权重下配置接收的路由调用比例：低权重优先成本效益高的 Qwen3，高权重优先性能较强的 o4-mini。

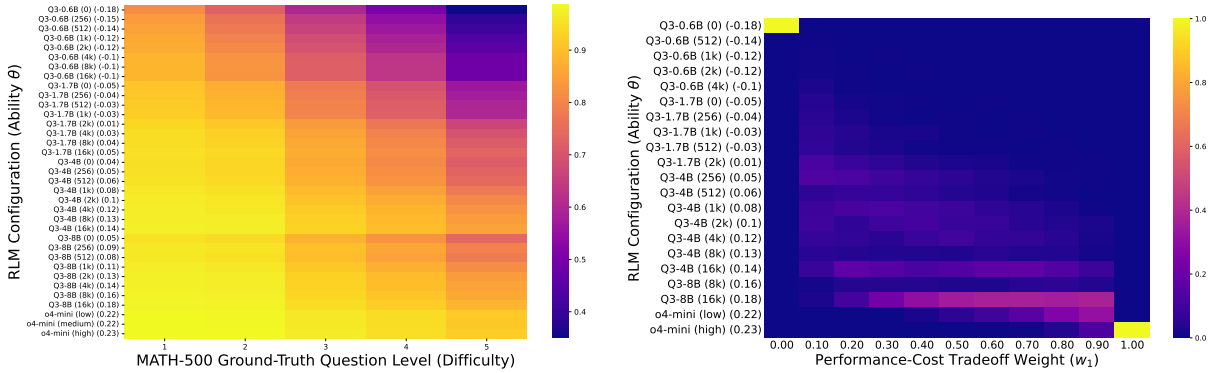


图 3: RADAR 的可解释问题难度与配置能力估计。左：MATH-500 中五个真实难度等级的问题上，各配置的平均预测正确率；难度越高，能力更强的配置预测正确率越高。右：随性能—成本权重变化，不同 RLM 配置被路由调用的比例；低权重更偏向 Qwen3（成本），高权重更偏向 o4-mini（性能）。

原论文 Fig. 3 的英文坐标轴、模型排序、能力数值和色条均按原样保留。

极小的实时路由延迟 我们测量 RADAR 的延迟，并与回答问题的最小 RLM 配置（Qwen3-0.6B、0 推理预算）比较。在 MATH-500 的 500 道题上重复运行三次，RADAR 的每题平均额外路由延迟为 6.89 ± 0.53 毫秒，而最小 RLM 生成答案所需时间为 869.56 ± 1.1 毫秒。相比之下，RADAR 的额外开销可以忽略。吞吐量分析见原文附录 B.9。

5 结论与未来工作（Conclusions and Future Work）

我们提出了 RADAR，一种推理能力与难度感知的路由框架：（1）将自适应推理形式化为 MOO；（2）利用 IRT 将问题自适应分配给不同的 RLM 模型—预算配置。RADAR 实现了良好的成本—性能权衡，在八个高难度推理基准上持续优于以往路由方法，并能较好地泛化到 OOD 问题。除效率外，RADAR 还通过呈现问题难度与模型能力提供可解释性，并通过自适应校准支持新 RLM 配置的即插即用式集成。

未来有几个有前景的方向。首先，我们希望将 RADAR 从文本扩展到多模态推理。其次，除推理预算外，纳入检索、工具使用和解码算法等额外配置，可以为超长上下文问答、深度研究等更广泛的应用提供细粒度路由决策。第三，可在其他约束场景中研究 RADAR，例如一批问题共享总预算上限的情况。这些方向体现出 RADAR 作为不断发展的 RLM 生态中具有理论依据、可解释的自适应推理基础框架的潜力。

致谢（Acknowledgements）

作者感谢 Tong Sun 和 Jaewook Lee 提供的有益讨论，也感谢匿名审稿人提出的宝贵意见。

可复现性声明（Reproducibility Statement）

我们对论文及附录进行了结构化组织，以便研究结果能够独立重新实现与复现。问题设置、路由目标和 IRT 建模细节见第 3 节；数据来源、预处理以及 ID/OOD 划分程序见原文附录 C；基线、评估协议、指标与其他实现细节见第 4 节及原文附录 D。

伦理声明（Ethics Statement）

我们确认遵守 ICLR 伦理准则。本研究只在公开推理基准上评估路由，不涉及人类受试者或个人身份信息；我们遵守数据集许可及署名要求，并在原文附录 C 中给出详细预处理流程。需要注意的是，通过路由得到的回答会继承底层 RLM 配置的属性，包括潜在社会偏见或安全问题。本文方法本身并不能缓解这些风险，因此，在没有针对具体应用领域的安全保障与偏见审计的情况下，应该谨慎部署。

参考文献（References，保留英文）

以下条目根据原论文第 10—14 页的参考文献整理，保留英文及原有文献顺序。

Pranjal Aggarwal and Sean Welleck. L1: Controlling how long a reasoning model thinks with reinforcement learning. arXiv preprint arXiv:2503.04697, 2025.

Maria-Florina Balcan, Steve Hanneke, and Jennifer Wortman Vaughan. The true sample complexity of active learning. Machine learning, 80(2):111–139, 2010.

Allan Birnbaum. Some latent trait models and their use in inferring an examinee's ability. Statistical theories of mental test scores, 1968.

Jorgen Branke, Kalyanmoy Deb, Kaisa Miettinen, and Roman Slowinski. Multiobjective Optimization: Interactive and Evolutionary Approaches. Springer Science & Business Media, 2008.

Lingjiao Chen, Matei Zaharia, and James Zou. Frugalgpt: How to use large language models while reducing cost and improving performance. arXiv preprint arXiv:2305.05176, 2023.

Zhou Chen, Zhiqiang Wei, Yuqi Bai, Xue Xiong, and Jianmin Wu. Tagrouter: Learning route to llms through tags for open-domain text generation tasks. arXiv preprint arXiv:2506.12473, 2025.

Christine DeMars. Item response theory. Oxford University Press, 2010.

Dujian Ding, Ankur Mallick, Chi Wang, Robert Sim, Subhabrata Mukherjee, Victor Ruhle, Laks VS Lakshmanan, and Ahmed Hassan Awadallah. Hybrid llm: Cost-efficient and quality-aware query routing. arXiv preprint arXiv:2404.14618, 2024.

Dheeru Dua, Yizhong Wang, Pradeep Dasigi, Gabriel Stanovsky, Sameer Singh, and Matt Gardner. Drop: A reading comprehension benchmark requiring discrete reasoning over paragraphs. arXiv preprint arXiv:1903.00161, 2019.

Michael TM Emmerich and André H Deutz. A tutorial on multiobjective optimization: fundamentals and evolutionary methods. Natural computing, 17(3):585–609, 2018.

Aryo Pradipta Gema, Joshua Ong Jun Leang, Giwon Hong, Alessio Devoto, Alberto Carlo Maria Mancino, Rohit Saxena, Xuanli He, Yu Zhao, Xiaotang Du, Mohammad Reza Ghasemi Madani, et al. Are we done with mmlu? arXiv preprint arXiv:2406.04127, 2024.

Soumya Suvra Ghosal, Souradip Chakraborty, Avinash Reddy, Yifu Lu, Mengdi Wang, Dinesh Manocha, Furong Huang, Mohammad Ghavamzadeh, and Amrit Singh Bedi. Does thinking more always help? understanding test-time scaling in reasoning models. arXiv preprint arXiv:2506.04210, 2025.

Maharshi Gor, Hal Daumé III, Tianyi Zhou, and Jordan Boyd-Graber. Do great minds think alike? investigating human-ai complementarity in question answering with caimira. arXiv preprint arXiv:2410.06524, 2024.

Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. arXiv

preprint arXiv:2501.12948, 2025.

Steve Hanneke. Theory of active learning. Foundations and Trends in Machine Learning, 7(2-3), 2014.

Michael Hassid, Gabriel Synnaeve, Yossi Adi, and Roy Schwartz. Don’ t overthink it. preferring shorter thinking chains for improved llm reasoning, 2025. URL https://arxiv.org/abs/ 2505.17813.

Dan Hendrycks, Collin Burns, Steven Basart, Andrew Critch, Jerry Li, Dawn Song, and Jacob Steinhardt. Aligning ai with shared human values. Proceedings of the International Conference on Learning Representations (ICLR), 2021a.

Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. Measuring massive multitask language understanding. Proceedings of the International Conference on Learning Representations (ICLR), 2021b.

Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the math dataset. arXiv preprint arXiv:2103.03874, 2021c.

Valentin Hofmann, David Heineman, Ian Magnusson, Kyle Lo, Jesse Dodge, Maarten Sap, Pang Wei Koh, Chun Wang, Hannaneh Hajishirzi, and Noah A Smith. Fluid language model benchmarking. In Second Conference on Language Modeling, 2025.

Jialiang Hong, Taihang Zhen, Kai Chen, Jiaheng Liu, Wenpeng Zhu, Jing Huo, Yang Gao, Depeng Wang, Haitao Wan, Xi Yang, Boyan Wang, and Fanyu Meng. Reconsidering overthinking: Penalizing internal and external redundancy in cot reasoning, 2025. URL https://arxiv.org/abs/2508.02178.

Bairu Hou, Yang Zhang, Jiabao Ji, Yujian Liu, Kaizhi Qian, Jacob Andreas, and Shiyu Chang. Thinkprune: Pruning long chain-of-thought of llms via reinforcement learning. arXiv preprint arXiv:2504.01296, 2025.

Qitian Jason Hu, Jacob Bieker, Xiuyu Li, Nan Jiang, Benjamin Keigwin, Gaurav Ranganath, Kurt Keutzer, and Shriyash Kaustubh Upadhyay. Routerbench: A benchmark for multi-llm routing system. arXiv preprint arXiv:2403.12031, 2024.

Shijue Huang, Hongru Wang, Wanjun Zhong, Zhaochen Su, Jiazhan Feng, Bowen Cao, and Yi R Fung. Adactrl: Towards adaptive and controllable reasoning via difficulty-aware budgeting. arXiv preprint arXiv:2505.18822, 2025.

Carlos E Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, and Karthik R Narasimhan. SWE-bench: Can language models resolve real-world github issues? In The Twelfth International Conference on Learning Representations, 2024. URL https://openreview.net/forum?id=VTF8yNQM66.

Ralph Keeney and Howard Raiffa. Decisions with Multiple Objectives: Preferences and Value Tradeoffs. Cambridge University Press, 1993.

Satyapriya Krishna, Kalpesh Krishna, Anhad Mohananey, Steven Schwarcz, Adam Stambler, Shyam Upadhyay, and Manaal Faruqui. Fact, fetch, and reason: A unified evaluation of retrievalaugmented generation. arXiv preprint arXiv:2409.12941, 2024.

Merve ¸Sahin Kür¸sad. The effects of different item selection methods on test information and test efficiency in computer adaptive testing. Journal of Measurement and Evaluation in Education and Psychology, 14(1):33–46, 2023.

Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph E. Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large language model serving with pagedattention, 2023. URL https://arxiv.org/abs/2309.06180.

Celine Lee, Alexander M Rush, and Keyon Vafa. Critical thinking: Which kinds of complexity govern optimal

reasoning length? arXiv preprint arXiv:2504.01935, 2025.

Frederic M Lord. A theory of test scores and their relation to the trait measured. ETS Research Bulletin Series, 1951(1):i–126, 1951.

Frederic M Lord. Applications of item response theory to practical testing problems. Routledge, 2012.

Pan Lu, Hritik Bansal, Tony Xia, Jiacheng Liu, Chunyuan Li, Hannaneh Hajishirzi, Hao Cheng, KaiWei Chang, Michel Galley, and Jianfeng Gao. Mathvista: Evaluating mathematical reasoning of foundation models in visual contexts. In International Conference on Learning Representations (ICLR), 2024.

MAA. MAA Invitational Competitions; Mathematical Association of America —maa.org. https://maa.org/maa-invitational-competitions/, 2024. [Accessed 03-09-2025].

Timothy Marler and Jasbir Arora. Survey of multi-objective optimization methods for engineering. Structural and Multidisciplinary Optimization, 26(6):369–395, 2004.

Guangyu Meng, Qingkai Zeng, John P. Lalor, and Hong Yu. A psychology-based unified dynamic framework for curriculum learning, 2024. URL https://arxiv.org/abs/2408.05326.

Kaisa Miettinen. Nonlinear multiobjective optimization, volume 12. Springer Science & Business Media, 1999.

Niklas Muennighoff, Zitong Yang, Weijia Shi, Xiang Lisa Li, Li Fei-Fei, Hannaneh Hajishirzi, Luke Zettlemoyer, Percy Liang, Emmanuel Candès, and Tatsunori Hashimoto. s1: Simple test-time scaling. arXiv preprint arXiv:2501.19393, 2025.

Tadahiko Murata and Hisao Ishibuchi. MOGA: Multi-objective genetic algorithms. In Proceedings of 1995 IEEE International Conference on Evolutionary Computation, pp. 289–294, 1995.

Isaac Ong, Amjad Almahairi, Vincent Wu, Wei-Lin Chiang, Tianhao Wu, Joseph E Gonzalez, M Waleed Kadous, and Ion Stoica. Routellm: Learning to route llms with preference data. arXiv preprint arXiv:2406.18665, 2024.

OpenAI. Introducing openai o3 and o4-mini. https://openai.com/index/ introducing-o3-and-o4-mini/, April 2025. Accessed: 2025-09-24.

OpenAI and et al. Openai o1 system card, 2024. URL https://arxiv.org/abs/2412.16720.

Felipe Maia Polo, Lucas Weber, Leshem Choshen, Yuekai Sun, Gongjun Xu, and Mikhail Yurochkin. tinybenchmarks: evaluating llms with fewer examples. In Proceedings of the 41st International Conference on Machine Learning, ICML' 24. JMLR.org, 2024.

Antonin Ponsich, Antonio Jaimes, and Carlos Coello. A survey on multiobjective evolutionary algorithms for the solution of the portfolio optimization problem and other finance and economics applications. IEEE Transactions on Evolutionary Computation, 17(3):321–344, 2013.

Georg Rasch. Studies in mathematical psychology: I. probabilistic models for some intelligence and attainment tests. 1960.

M.D. Reckase. Multidimensional Item Response Theory. Springer New York, 2009. ISBN 9780387899763. doi: 10.1007/978-0-387-89976-3. URL http://dx.doi.org/10.1007/ 978-0-387-89976-3.

David Rein, Betty Li Hou, Asa Cooper Stickland, Jackson Petty, Richard Yuanzhe Pang, Julien Dirani, Julian Michael, and Samuel R Bowman. Gpqa: A graduate-level google-proof q&a benchmark. In First Conference on Language Modeling, 2024.

Pedro Rodriguez, Joe Barrow, Alexander Miserlis Hoyle, John P. Lalor, Robin Jia, and Jordan Boyd-Graber. Evaluation examples are not equally informative: How should that change NLP leaderboards? In Chengqing Zong, Fei Xia, Wenjie Li, and Roberto Navigli (eds.), Proceedings of the 59th Annual Meeting of the Association for

Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers), pp. 4486–4503, Online, August 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.acl-long.346. URL https://aclanthology.org/2021.acl-long.346/.

Marija Šakota, Maxime Peyrard, and Robert West. Fly-swat or cannon? cost-effective language model choice via meta-modeling. In Proceedings of the 17th ACM International Conference on Web Search and Data Mining, pp. 606–615, 2024.

Alexander Scarlatos, Nigel Fernandez, Christopher Ormerod, Susan Lottridge, and Andrew Lan. Smart: Simulated students aligned with item response theory for question difficulty prediction. arXiv preprint arXiv:2507.05129, 2025.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. arXiv preprint arXiv:2402.03300, 2024.

Parshin Shojaee, Iman Mirzadeh, Keivan Alizadeh, Maxwell Horton, Samy Bengio, and Mehrdad Farajtabar. The illusion of thinking: Understanding the strengths and limitations of reasoning models via the lens of problem complexity, 2025. URL https://arxiv.org/abs/2506. 06941.

Wei Song, Zhenya Huang, Cheng Cheng, Weibo Gao, Bihan Xu, GuanHao Zhao, Fei Wang, and Runze Wu. Irt-router: Effective and interpretable multi-llm routing via item response theory. arXiv preprint arXiv:2506.01048, 2025.

Jinyan Su and Claire Cardie. Thinking fast and right: Balancing accuracy and reasoning length with adaptive rewards. arXiv preprint arXiv:2505.18298, 2025.

Jinyan Su, Jennifer Healey, Preslav Nakov, and Claire Cardie. Between underthinking and overthinking: An empirical study of reasoning length and correctness in llms. arXiv preprint arXiv:2505.00127, 2025.

Wim J. van der Linden and Ronald K. Hambleton (eds.). Handbook of Modern Item Response Theory. Springer, New York, NY, 1997.

Howard Wainer, Neil J Dorans, Ronald Flaugher, Bert F Green, and Robert J Mislevy. Computerized adaptive testing: A primer. Routledge, 2000.

Lihui Wang, Amos Ng, and Kalyanmoy Deb. Multi-Objective Evolutionary Optimisation for Product Design and Manufacturing. Springer, 2011.

Siyuan Wang, Zhongkun Liu, Wanjun Zhong, Ming Zhou, Zhongyu Wei, Zhumin Chen, and Nan Duan. From lsat: The progress and challenges of complex reasoning. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022.

Xiangqi Wang, Yue Huang, Yanbo Wang, Xiaonan Luo, Kehan Guo, Yujun Zhou, and Xiangliang Zhang. Adareasoner: Adaptive reasoning enables more flexible thinking. arXiv preprint arXiv:2505.17312, 2025.

Yubo Wang, Xueguang Ma, Ge Zhang, Yuansheng Ni, Abhranil Chandra, Shiguang Guo, Weiming Ren, Aaran Arulraj, Xuan He, Ziyan Jiang, et al. Mmlu-pro: A more robust and challenging multitask language understanding benchmark. Advances in Neural Information Processing Systems, 37:95266–95290, 2024.

Yuhui Xu, Hanze Dong, Lei Wang, Doyen Sahoo, Junnan Li, and Caiming Xiong. Scalable chain of thoughts via elastic reasoning. arXiv preprint arXiv:2505.05315, 2025.

An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. Qwen3 technical report. arXiv preprint arXiv:2505.09388, 2025.

Shunyu Yao, Noah Shinn, Pedram Razavi, and Karthik R Narasimhan. τ-bench: A benchmark for Tool-Agent-User interaction in real-world domains. In The Thirteenth International Conference on Learning Representations, 2025.

URL https://openreview.net/forum?id=roNSXZpUDN.

Zishun Yu, Tengyu Xu, Di Jin, Karthik Abinav Sankararaman, Yun He, Wenxuan Zhou, Zhouhao Zeng, Eryk Helenowski, Chen Zhu, Sinong Wang, et al. Think smarter not harder: Adaptive reasoning with inference aware optimization. arXiv preprint arXiv:2501.17974, 2025.

Linan Yue, Yichao Du, Yizhi Wang, Weibo Gao, Fangzhou Yao, Li Wang, Ye Liu, Ziyu Xu, Qi Liu, Shimin Di, et al. Don't overthink it: A survey of efficient r1-style large reasoning models. arXiv preprint arXiv:2508.02120, 2025.

Richard Zhang and Daniel Golovin. Random hypervolume scalarizations for provable multiobjective black box optimization. In Proceedings of the 37th International Conference on Machine Learning, 2020.

Xuechen Zhang, Zijian Huang, Ege Onur Taga, Carlee Joe-Wong, Samet Oymak, and Jiasi Chen. Efficient contextual llm cascades through budget-constrained policy learning. Advances in Neural Information Processing Systems, 37:91691–91722, 2024.

Yiqun Zhang, Hao Li, Jianhao Chen, Hangfan Zhang, Peng Ye, Lei Bai, and Shuyue Hu. Beyond gpt-5: Making llms cheaper and better via performance-efficiency optimized routing, 2025. URL https://arxiv.org/abs/2508.12631.

Wanjun Zhong, Siyuan Wang, Duyu Tang, Zenan Xu, Daya Guo, Jiahai Wang, Jian Yin, Ming Zhou, and Nan Duan. Ar-lsat: Investigating analytical reasoning of text, 2021.

Vilém Zouhar, Peng Cui, and Mrinmaya Sachan. How to select datapoints for efficient human evaluation of nlg models? arXiv preprint arXiv:2501.18251, 2025.

译本范围及公式核对说明

本文件包含原论文摘要、第 1—5 章、致谢、可复现性声明、伦理声明及英文参考文献。附录 A—E 未收录（它们包括更多结果表、附加图、数据集、硬件及实现细节），请参见原论文 PDF。

公式核对：本译本依照原始 PDF 对照复核九个带编号的公式（1）—（9），保留各式变量、上下标、求和范围、极值算子、权重和符号；图 1—3 直接提取自原论文页面的矢量图；表 1—3 根据原文逐格录入数值。需注意原文式（6）的记号 $c_q(g)$ 虽含下标 q，但右侧是在训练问题集 $\mathcal{Q}$ 上求平均的表达式；本译本保留原样，不擅自修改符号。第 3.1 节的配置集合表达式不带原文公式编号，亦按照正文原意排版。

原文来源：Nigel Fernandez, Branislav Kveton, Ryan A. Rossi, Andrew S. Lan, and Zichao Wang. *RADAR: Reasoning-Ability and Difficulty-Aware Routing for Reasoning LLMs*. ICLR 2026. arXiv:2509.25426v3 (2026-03-10).